

CRISP: 面向稀疏与高维配方数据的单纯形约束成分比例插补

Compositional Ratio-based Imputation with Simplex Projection for Sparse and High-Dimensional Formulation Data

(中文版, 用于理解与展示; 投稿版为英文)

摘要

材料配方数据(合金、玻璃、水泥、电解液)是成分数据: 每个样本是各组分比例的向量, 总和固定; 配方中刻意不添加的组分表现为结构零。实践中这类矩阵包含两种不同的缺失信息——结构零(某组分未添加)与缺失值(记录丢失)——而标准的插补方法都无法同时处理两者: 对数比变换在零值处崩溃($\log 0$), 朴素方法则违反单纯形约束、产生物理上不可行的配方。

我们提出 CRISP (成分比例插补 + 单纯形投影), 一类约束保证的插补器, 显式区分结构零与缺失值。缺失项按完整行估计的配比轮廓(归一化比例的中位数)比例分配, 结果构造性满足单纯形约束。我们证明该分配是 Dirichlet 条件均值的经验贝叶斯估计(单纯形上信息量最少的补法), 并给出插补误差上界: 可收缩的轮廓项 $O(M^{1/2})$ + 不可约的数据不确定性项。

方法的主战场是材料数据库常见的 $n < d$ 高维小样本配方数据。在合成 $n < d$ 实验中, CRISP 显著降低插补误差 (Wilcoxon 配对检验 $p < 0.01$, 多数配置; 误差低 2.0 - 2.5 倍), 并显著优于低秩矩阵补全

SoftImpute (其在成分数据上失败, 因为低秩假设被结构零与闭约束破坏)。在真实材料子集(玻璃、水泥、钢、合金)上, CRISP 显著优于 MICE ($p < 0.01$, 各 20 个子集)。关键机制是 CRISP 利用闭约束: 当一行仅一个缺失组分时, CRISP 精确恢复它 ($x_i = 100$ 已知), 而回归插补器忽略这条信息。基线违反单纯形约束 (SumDev 最高 14) 而 CRISP 到机器精度满足。在低缺失率稠密数据上, CRISP 与 MICE 精度在 5 个数据集的 3 个上无统计显著差异 (2 个上略差), 但严格保证 SumDev=0、零参数、 $n < d$ 可用。标准成分零处理包 zCompositions 完全无法运行于结构零+缺失混合数据。

关键词: 成分数据; 结构零; 插补; 单纯形约束; $n < d$; 小样本; 材料信息学

1 引言

材料配方优化——合金设计、玻璃配方、水泥与电解液配方——把每个候选样本视为组分分数向量。两个数据质量问题主导真实数据集: (1) 结构零: 配方刻意省略某些组分, 0

是真实信息(未添加)而非缺失测量, 在我们的合金数据中 55 - 86% 的组分项是结构零; (2) 缺失值: 个别记录丢失, 产生需插补的 NA。

两者的并存是材料数据库的常态, 但标准方法都处理不好。对数比变换方法 (Aitchison 距离的 impKNNa、impCoda、zCompositions::lrEM/lrSVD) 要求严格正数; 结构零迫使伪计数, 把未添加变成微量存在。这些方法的 Aitchison 模式在含零数据上直接崩溃 ($\log 0$ / NA 不允许)。因此我们用官方基线 impKNNa 的欧氏模式 (把 0 当普通数值) 作为可运行基线, 但它违反单纯形约束。朴素/回归/低秩插补 (KNN、均值、MICE、SoftImpute) 不做闭合步骤, 产出违反约束的矩阵。违反在 CRISP 约束保证真正重要的场景最严重: $n < d$ 数据与高缺失率 (SumDev 7 - 8; 50 - 70% 缺失率时基线最高 24 - 55)。

主要贡献: (1) 显式区分结构零与缺失——零保留, 只插补缺失; (2) 构造性单纯形保证——SumDev=0 是设计出来而非后处理投影; (3) plug-in 经验贝叶斯解释——分配匹配 Dirichlet 条件均值 (默认中位数轮廓, 亦支持均值/几何均值), 带可证明的误差上界; (4) $n < d$ 能力——只需列中位数, 无协方差、无调参, 是回归 (MICE) 与低秩 (SoftImpute) 插补器都退化的场景。

2 方法

2.1 记号

设 $S = \{x \in \square\square\square : \sum \square x\square = 100\}$ 为成分单纯形。完整成分 $x/100 \sim \text{Dirichlet}(\alpha)$ 。样本 i 的已知部分为 x_K ，缺失部分为 x_M ，剩余量 $R = 100 - \sum_{k \in K} x_k$ 。C 为完整行集合， $M = |C|$ 。

2.2 CRISP 算法

轮廓 $p\square$ 是完整行归一化比例的逐列中位数。缺失项按比例分配：

$$x\square\square = (p\square\square / \sum_{m \in M} p\square\square) \cdot R, \quad \square j \in M.$$

结构零从不被改动。实现还提供 LCRISP (k 近邻局部轮廓) 与 AutoCRISP (自适应切换) 变体；本文仅评估基础 CRISP，变体的实证比较留待后续。复杂度为 $O(d \cdot M)$ (轮廓) 与 $O(d)$ (每样本)。

2.3 理论

引理 1 (轮廓一致性)：在 MCAR 且 $x/100 \sim \text{Dirichlet}(\alpha)$ 下，均值与几何均值轮廓收敛到 $\alpha / \sum \alpha$ ，且 $E \|p\square - \alpha / \sum \alpha\| = O(M^{-1/2})$ (大数定律/中心极限定理；几何均值用 Dirichlet 的 digamma 恒等式)。中位数轮廓以同速率收敛到总体中位数，仅当 Dirichlet 分量满足对称性条件时等于 $\alpha / \sum \alpha$ ；实践中三种轮廓的插补 MAE 差距 <4% (消融见 §3.2)。我们默认保留中位数 (鲁棒性，命题 5)，并提供几何均值轮廓作为可选变体。

定理 2 (插补误差上界)：对缺失坐标 j ， $E|x\square\square - x\square^*| \leq O(M^{-1/2} \cdot R) + \sqrt{(2/\pi) \cdot \text{sd}(x\square | x_K)}$ 。第一项随完整行收缩；第二项是不可约的条件不确定性 ($\sqrt{(2/\pi)}$ 假设正态条件残差，一般分布用 Jensen 界 $\leq \text{sd}$)。

plug-in 说明：CRISP 分配等于 Dirichlet 条件均值这一贝叶斯解读，对均值/几何均值轮廓严格成立；对中位数轮廓需对称性条件，否则中位数收敛到总体中位数、等式近似成立。所有情况下轮廓都是 plug-in 估计，而非完整后验计算。完整陈述与证明见补充材料 (PROOFS)。

命题 5 (维度鲁棒性，经验性)：CRISP 轮廓逐列估计 (中位数)，无跨维度回归，故对任意 d/n 良定义。回归型插补 (MICE) 每步拟合 $x\square \sim X_{[-j]}$ ： $n < d$ 时无正则最小二乘不可识别，正则化实现的外推误差随 d/n 增大——与 $n < d$ 实验中 MICE 误差急剧退化而 CRISP 保持平坦一致。

2.4 实验设计

低缺失率数据集 (5 个，四个材料体系)：ge 耐火合金 (86×9, 55% 零)、玻璃 (40×8, 21%)、合成 (300×8, 42%)、钢 (312×13, 17%)、水泥 (UCI, 1030×7, 20%)。 $n < d$ 数据集：合成 $n \in \{20, 25, 30\}$ 、 $d \in \{40, 50, 60\}$ ；以及钢 ($n=10, d=13$)、玻璃 ($n=6, d=8$)、水泥 ($n=6, d=7$)、ge ($n=8, d=9$) 的真实 $n < d$ 子集，各 20 个随机子集。缺失机制：MCAR/MAR/MNAR，低缺失率 10%/20%、 $n < d$ 10%/30%。

关键协议细节：缺失只在非零项上施加——结构零从不被标记为缺失。所有方法收到同一缺失掩码，结构零不被任何方法改动，故评估隔离了缺失值插补任务。

基线：官方 robCompositions::impKNNa (欧氏模式)、R missForest、scikit-learn IterativeImputer (MICE)、KNNImputer、列均值、SoftImpute (低秩矩阵补全，秩 5 SVD 阈值化；秩 2/5/10 敏感性确认其在成分数据上全失败)。Aitchison/impCoda/lrEM/zCompositions 报告为无法运行于混合零/NA 数据。

指标：缺失项 MAE (Python 方法 20 个随机缺失种子，均值 ± 标准差；R 基线单种子并排除于配对检验之外)、SumDev (单纯形违反)、CRISP 对每个 Python 基线的配对 Wilcoxon 符号秩检验。

3 结果

3.1 低缺失率数据 (20 种子均值；标准差见附录)

表 1. 缺失项 MAE，MCAR 10%。

耐火合金 (55%)
玻璃 (21%)
合成 (42%)
钢 (17%)
水泥 (20%)

合成 n<d	22%)
水泥/合成	16%)
玻璃/水泥	20%)

诚实发现 1：低缺失率数据上，CRISP 在稀疏数据集（玻璃）最好或并列，而 MICE 在水泥/合成上中等程度更好 ($p<0.001$ / $p=0.009$ 有利于 MICE)，其余相当 (ge $p=0.11$ 、钢 $p=0.37$ 、玻璃 $p=0.60$)。因此 CRISP 的原始精度与 MICE 在 5 个数据集的 3 个上无统计显著差异、在 2 个上略差——其差异化在于严格约束保证 (SumDev=0)、结构零语义、零调参、 $n<d$ 能力，而非精度。

3.2 $n<d$ 场景（CRISP 的主要优势）

表 2. 合成 $n<d$ 数据，MCAR 10%（20 种子均值）。

数据集	CRISP/基线(MICE)
合成 n<d	3.2
水泥/合成	7-8
玻璃/水泥	7-8
钢	7-8
ge	7-8

关键发现 2：合成 $n<d$ 场景，CRISP 显著降低插补误差（配对 Wilcoxon $p<0.01$ 占 70% 配置，MCAR 10% 时 $p<0.001$ ）并显著优于 SoftImpute ($p<0.001$ 全配置——低秩补全在成分数据上失败，误差高 3-12 倍)。基线违反单纯形约束 (SumDev 7-8) 而 CRISP 到机器精度满足。不显著的 30% 配置集中在真实扩展数据集 (ge_nd) 与高缺失率 (30%) MAR/MNAR 情形，完整 p 值矩阵见附录。

真实材料 $n<d$ 证据（各 20 子集）：

数据集	$n<d$ 子集)
玻璃	n=60d=8)
水泥	n=60d=7)
钢	n=100d=13)
ge	n=80d=9)

关键发现 3：四个真实材料数据的 $n<d$ 子集上，CRISP 全部显著优于 MICE ($p<0.01$)。注意：这些子集从小池重叠抽样（玻璃仅 40 行， $n=6$ 的 20 次抽样高度重叠），配对 Wilcoxon 的 p 值应视为指示性而非正式显著性；主要统计证据是合成 $n<d$ 实验（独立缺失抽取）与闭合恢复机制本身。

近精确恢复的机制：这些小样本子集中，缺失被单缺失组分行主导——玻璃/水泥子集 100% 的缺失行、钢 89%、合成 $n<d$ 40% 是单缺失组分。对单缺失组分行，CRISP 分配退化为 $x_{ij} = R_{ij} = 100$ Σ 已知，即利用闭合约束（行和=100）精确恢复缺失项。这是玻璃/水泥达到 MAE 0.000 的原因——不是伪影，而是方法利用了回归插补器忽略的信息（行和已知）。我们把这种闭合约束恢复视为 CRISP 在 $n<d$ 场景的核心性质。

扩展真实高维数据：一个 ge 衍生的 $n=20, d=30$ 数据集（86% 零）在 MCAR 10% 时未显示 CRISP 优势（MICE 3.87 vs CRISP 4.27，不显著）； $n<d$ 优势建立在小子集与合成池上，在更大真实高维数据上仍有待确认。我们不声称普遍的 $n<d$ 支配。

MAR/MNAR（低缺失率）：表 3 报告 10% 缺失率下的 MAR/MNAR。CRISP 在 ge/玻璃/合成的 MNAR/MAR 下最好或接近最好，并处处优于对数比基线；MICE 在水泥上仍具竞争力或更好。完整网格见附录。

数据集	Na
合成	0.3
水泥	0.5
玻璃	24%)

合成	0.17%
水泥	0.92%
玻璃	0.92%
陶瓷	0.92%
橡胶	0.92%
塑料	0.92%

轮廓选择（消融）：合成 $n < d$ 数据上，几何均值轮廓（CoDA 标准中心，满足子组合一致性）比中位数略精确（MAE 3.28 vs 3.39；均值轮廓 3.97，差距 <4%）。我们保留中位数出于鲁棒性：在人为污染一个完整行（某组分 $\times 10$ 后重新闭合）时，中位数轮廓的插补误差不变而均值轮廓退化。两种选择都保持闭合约束，定性结论不依赖轮廓选择；几何均值变体在发布代码中作为可选提供。

3.3 约束保证

CRISP 输出恒满足 $\sum x_i = 100$ (SumDev=0, 构造性)。基线违反：低缺失率下 MICE 0.0 - 0.3、 $n < d$ 时 7 - 8；SoftImpute 与 impKNNa 0.2 - 7.8；KNN 0.1 - 8；均值 0.1 - 13。50 - 70% 缺失率时基线违反增至 24 - 55 而 CRISP 保持 0；我们诚实说明：稠密数据极端缺失率下 CRISP 原始精度中等（MICE 可能更准）——高缺失率不是 CRISP 声称的强项，其保证在那里是约束而非精度。

3.4 结构零保留

在共享协议下（缺失仅在非零项、结构零不被改动），所有方法都保留现有零；CRISP 的独特之处在于在可行分配内构造性保留它们，而非把零留在违反约束的矩阵中。

3.5 理论验证

轮廓误差随 M 递减 (0.065 $\rightarrow$ 0.039)；插补 MAE 稳定在不可约项 (≈ 9.1)，与定理 2 一致。

3.6 下游应用

在 $n < d$ 数据 + 20% 缺失下，仅 CRISP 插补矩阵在下游代理模型中保持正的预测 R^2 (0.11)，而 MICE/KNN/均值崩塌为负 R^2 (-0.13 至 -0.31)。低缺失率数据上 CRISP 插补矩阵在玻璃/ge 给出最接近无缺失基线的 R^2 。闭环配方优化效率未被任何插补器在这些小数据集上一致改善——如实的局限。

4 讨论

$n < d$ 场景是 CRISP 的主战场。材料数据库常是高维小样本：几十个配方、几十个组分、每样本大多缺失。该场景回归插补器（MICE）退化（命题

5）、低秩补全（SoftImpute）在成分数据上直接失败，其输出物理不可行（SumDev 7 - 8）。CRISP 只需列中位数，显著更准 ($p < 0.01$ ，合成与真实子集) 且严格可行。下游演示确认后果：仅 CRISP 插补矩阵在 $n < d$ 数据保持正预测 R^2 。

CRISP 不占优之处：低缺失率稠密或主导组分数据（水泥、合成、部分 ge）上，MICE 精度相当或中等更好；CRISP

那里的差异化是严格约束保证、结构零语义、零调参与可解释性。我们不声称该场景的精度支配。

为什么 plug-in 贝叶斯观点重要：CRISP 的分配是与观测部分一致的信息量最少的补法（plug-in 意义下），避免注入伪结构；误差上界解释了完整行为何有帮助（轮廓项）以及为何无法消除误差（不可约项）。

局限：(i) 全部实验为回溯，无前瞻性实验验证；(ii) 贝叶斯解读是 plug-in 而非精确；(iii) 一个扩展真实 $n < d$ 数据集 (ge) 不显著；(iv) 方法简单，我们声称的是对真实问题的稳健、约束保证、可证界的方案，而非全新估计器类别；(v) LCRISP/AutoCRISP 变体已实现但未实证评估。

5 结论

CRISP 是一个约束保证、结构零友好的插补方法，其主优势在材料配方数据的 $n < d$ 高维小样本场景——那里回归与低秩插补器既不准又物理不可行；其严格单纯形保证、零调参、可证明误差上界使其在其他场景成为可靠默认。实现、脚本与原始结果全部发布以保证可复现。

参考文献

1. Aitchison, J. (1982). *The Statistical Analysis of Compositional Data*. Chapman and Hall, London.
2. Templ, M., Hron, K., Filzmoser, P. (2011). robCompositions: an R-package for robust statistical analysis of compositional data. In *Compositional Data Analysis: Theory and Applications*, pp. 341–355. Wiley.
3. Palarea-Albaladejo, J., Martín-Fernández, J. A. (2015). zCompositions — R package for multivariate imputation of left-censored values. *Chemometrics and Intelligent Laboratory Systems*, 143, 85–96.
4. Stekhoven, D. J., Bühlmann, P. (2012). MissForest—non-parametric missing value imputation for mixed-type data. *Bioinformatics*, 28(1), 112–118.
5. van Buuren, S., Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
6. Mazumder, R., Hastie, T., Tibshirani, R. (2010). Spectral regularization algorithms for learning large incomplete matrices. *Journal of Machine Learning Research*, 11, 2287–2322.

注：本文中文版由英文投稿稿翻译，用于理解与展示；正式投稿请使用英文版并遵守期刊 AI 政策声明。